學號：R05922028　系級：資工碩二　姓名：林孟瑤

1.PCA of colored faces

1. (.5%) 請畫出所有臉的平均。

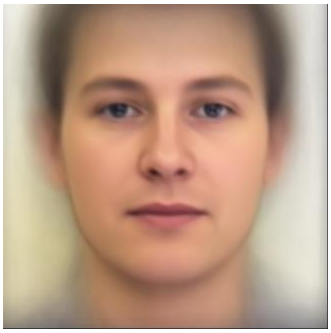

2. (.5%) 請畫出前四個 Eigenfaces， 也就是對應到前四大 Eigenvalues 的 Eigenvectors。


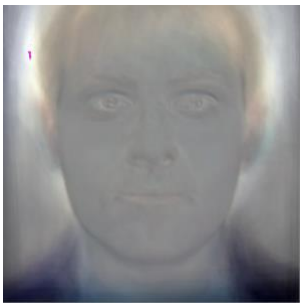

3. (.5%) 請從數據集中挑出任意四個圖片， 並用前四大 Eigenfaces 進行 reconstruction， 並畫出結果。


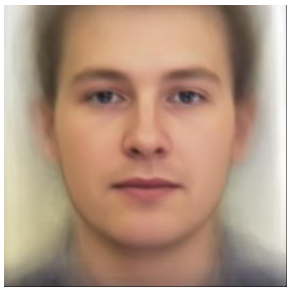

4. (.5%) 請寫出前四大 Eigenfaces 各自所佔的比重，請用百分比表示並四捨五入到小數點後一位。
    1. 21.6%
    2. 10.9%
    3. 7.2%
    4. 6.1%

2.Visualization of Chinese word embedding

1. (.5%) 請說明你用哪一個 word2vec 套件，並針對你有調整的參數說明那個參數的意義。

    Genism word2vec:

    - size:向量維度
    - alpha : learning rate
    - window: 往右看幾個字
    - workers:執行緒數目
    - min_count: 出現次數超過 min_count 才會被視為訓練資料

2. (.5%) 請在 Report 上放上你 visualization 的結果。

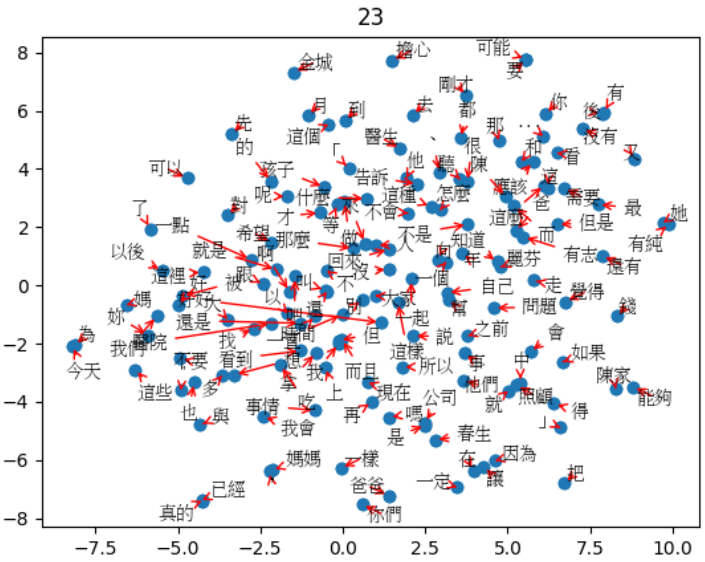

3. (.5%) 請討論你從 visualization 的結果觀察到什麼。

以圖的意義來說明, 較有關連的字詞會聚集在同一塊, 或是經常一起出現的字詞也會聚集在一起

我分別調整了兩個參數去做比較

1. size 也就是維度 這邊降低維度

   可以知道當我們維度太高, 則會分的太細

   而維度太低的話, 則會分不開來

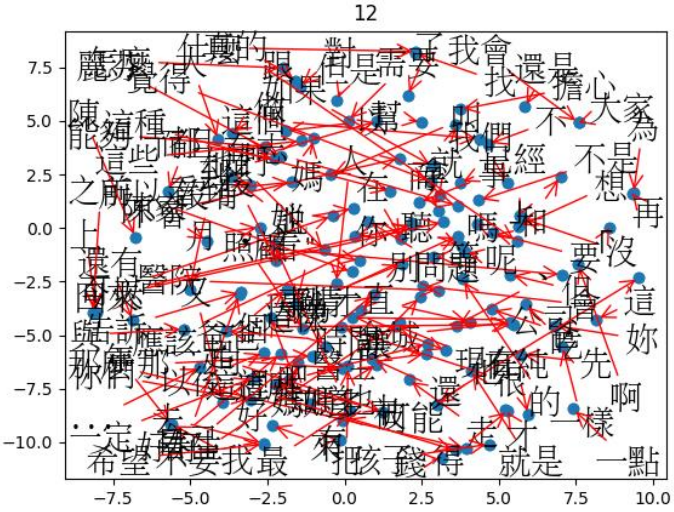

2. window 調高

   在其他參數相同的情況下, 將 window 調高, 可以讓各點的關聯較多一些

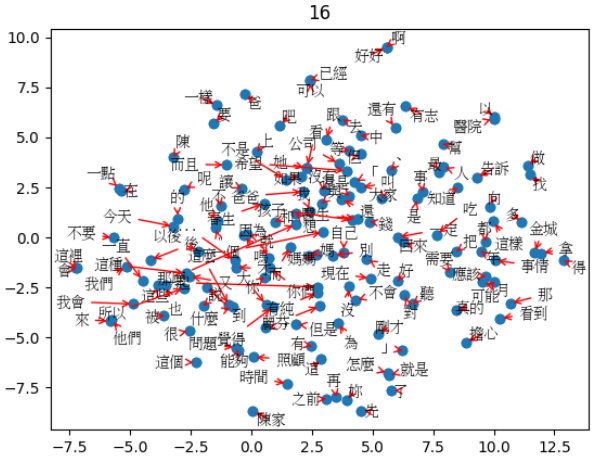

3.Image clustering

1. (.5%) 請比較至少兩種不同的 feature extraction 及其結果。(不同的降維方法或不同的 cluster 方法都可以算是不同的方法)

利用 PCA 降維去實作 image clustering 的結果很差:

result.csv 8 days ago by r05922028_yao add submission details	0.03602	0.03627

後來改用 autoencoder 效果進步很多

result.csv 4 days ago by r05922028_yao autoencoder	0.99372	0.99365

2. (.5%) 預測 visualization.npy 中的 label，在二維平面上視覺化 label 的分佈。

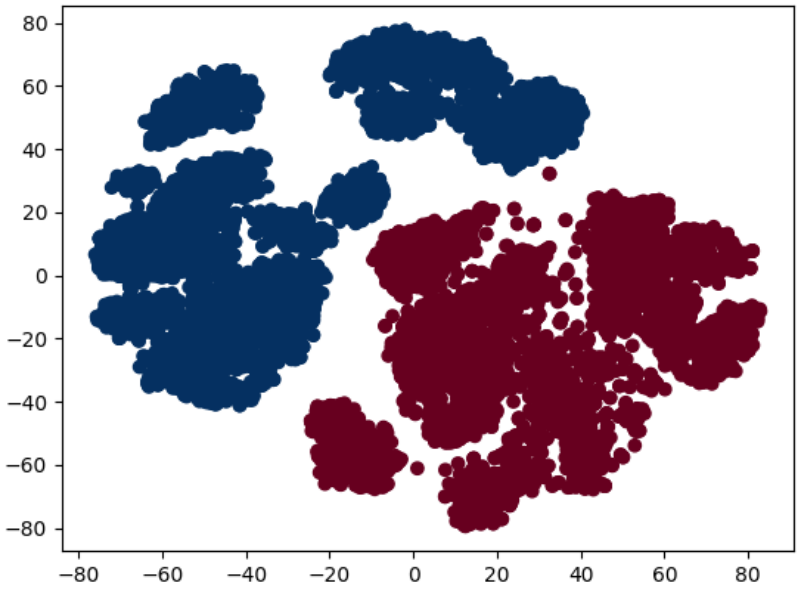

3. (.5%) visualization.npy 中前 5000 個 images 跟後 5000 個 images 來自不同 dataset。請根據這個資訊，在二維平面上視覺化 label 的分佈，接著比較和自己預測的 label 之間有何不同。